# 023\_Folien

2018年11月23日

```
In [1]: from matplotlib import pyplot as plt
    import numpy as np
    %matplotlib inline
```

## 1 Beschreibende Statistik

## 1.1 Übersicht

LagemaSS

Streuung

Graphiken

Mehrdimensionale Daten

## Abhängigkeit

- Korrelation
- Regression
  - linear
  - polynomial

## 1.2 Mehrdimensionale Daten - Regression

#### Korrelation

- Voraussetzung: Zusammenhang von zusammengehörigen Daten ist nachgewiesen
- Korrelationskoeffizient  $\neq 0$

### Beispiele:

- Strom und Spannung: festes Verhältnis gemäSS Ohmschen Gesetzes
- Luftdruck und Höhe über Meer: Barometrische Höhenformel

## 1.3 Frage: Wie stark hängt y von x ab?

#### Beispiel: Fahrstrecke x und Fahrzeit t

- Zusammenhang: je mehr Zeit t, desto weiter die Strecke s
  - linear  $x \sim t$
  - Proportionalitätsfaktor "Geschwindigkeit v":  $x = v \cdot t$
- Für x = 10km benötigen Sie t = 12Minuten

**Anwendung** Bei linearer Abhängigkeit  $x = v \cdot t$  erlaubt der Proportionalitätsfaktor Vorhersagen Beispielsweise: wie lang ist die zurückgelegte Strecke in 1 Sekunde?

$$x = v \cdot t = \frac{10 \text{km}}{10 \text{min}} \cdot 1s = \frac{10000 \text{m}}{10 \cdot 60 \text{s}} \cdot 1s = 16.7 m$$

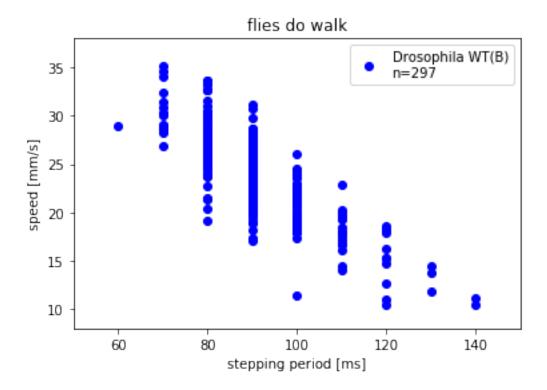
Ergebnis: In der Reaktionszeit von 1s legt ein Auto im Stadtverkehr 17m zurück

plt.xlabel('stepping period [ms]')

plt.ylabel('speed [mm/s]')
plt.legend(loc='upper right');

#### 1.3.1 Mehrere Messungen

Mehrere (n) Messungen  $y_i$  zu verschiedenen Werten der x-Variable, hier Schrittperiodendauer (Zeiten, Längen, Alter, Höhe, ...)



#### 1.3.2 Korrelation?

#### 1.3.3 Regression?

lineare Abhängigkeit - mehrere x-Werte (Periodendauern) - mehrere Messungen (Geschwindigkeit)

Ausgleichsgerade

### 1.3.4 Methode der Kleinsten Quadratischen Abweichung

(C. F. Gauss 1809, A. M. Legendre 1805)

$$\underset{a,b}{\operatorname{argmin}} \sum_{i} (y_i - f_{a,b}(x_i))^2$$

des linearen Zusammenhangs

$$y = f_{a,b}(x) = a \cdot x + b$$

führt zu

$$a = \frac{\sum_{i} (y_i - \bar{y}) x_i}{\sum_{i} (x_i - \bar{x}) x_i}$$

$$b = \bar{y} - a \cdot \bar{x}$$

Die Steigung oder lineare Abhängigkeit a wird auch Regressionskoeefizient genannt und entspricht

$$a = r_{XY} \cdot \frac{\sigma_Y}{\sigma_X}$$

$$a = \frac{\sum_{i} (y_{i} - \bar{y}) x_{i}}{\sum_{i} (x_{i} - \bar{x}) x_{i}}$$

$$= r_{XY} \frac{\sigma_{Y}}{\sigma_{X}}$$

$$= \frac{Cov(X, Y)}{\sigma_{X}\sigma_{Y}} \cdot \frac{\sigma_{Y}}{\sigma_{X}}$$

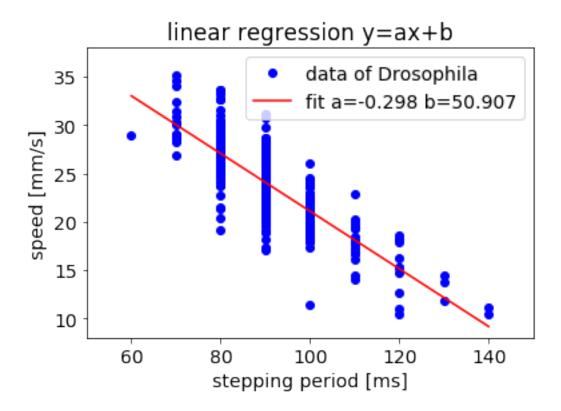
$$=$$

Im Allgemeinen

$$r_{XY} = r_{YX}$$
 $a_{XY} \neq a_{YX}$ 
 $a_{XY} \neq \frac{1}{a_{YY}}$ 

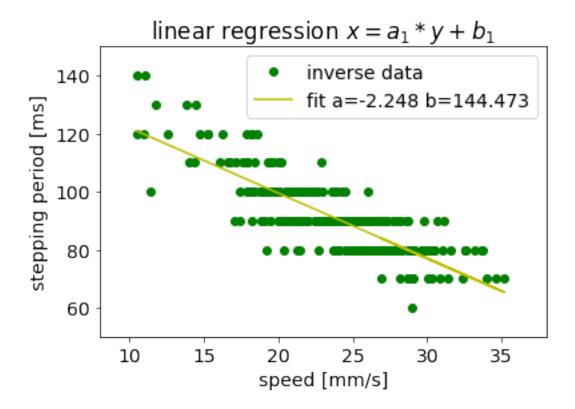
Später mehr...

```
In [7]: '''linear function y=f(x)=a*x+b
           input: x: scalar or np.array (x values)
                   a: scalar (regression parameter)
                   b: scalar (offset parameter)
           output: same type and size as x
        def fct_y( x, a, b ):
           return a*x + b
        ''' make handy names for data: '''
        x = data[0] # the period durations
        y = data[1] # the measured walking speed
        '''calculate linear regression according to formula above'''
        a = ((y - y.mean())*x).sum() / ((x - x.mean())*x).sum()
        b = y.mean() - a*x.mean()
        print('manually fitted: y = \{:.3f\}*x + \{:.3f\}'.format(a, b))
manually fitted: y = -0.298*x + 50.907
In [8]: '''show the fit result'''
                                                         # raw data as dots
        plt.plot(x, y, 'bo', label='data of Drosophila')
        plt.plot(x, fct_y(x, a, b), 'r-', label='fit a={:.3f} b={:.3f}'.format(a, b))
        plt.title('linear regression y=ax+b')
                                                                 # fitted line
        plt.axis((50, 150, 8, 38))
        plt.xlabel('stepping period [ms]')
        plt.ylabel('speed [mm/s]')
        plt.legend(loc='upper right');
```



### 1.3.5 fit with scipy.stats

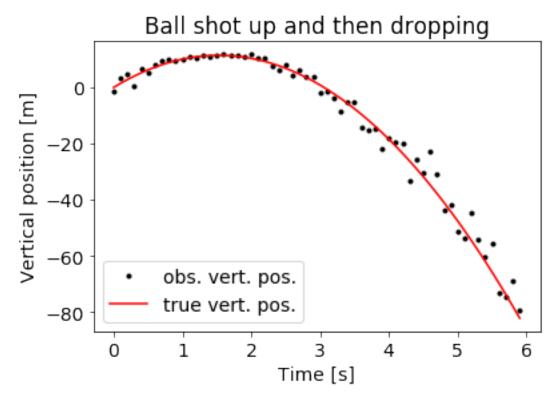
```
In [9]: '''fit it with scipy directly'''
       from scipy import stats
                                 # contains also fitting routines,
       fit = stats.linregress(x, y)
                                      # e.g. linear regression fit
       print('fitted by scipy: y = {:.3f}*x + {:.3f}'.format(fit.slope, fit.intercept))
fitted by scipy: y = -0.298*x + 50.907
In [11]: '''fit the reverse values x(y)'''
        fit_r = stats.linregress(y, x)
                                           # linear regression of reverse data
        print('linear fit: x = {:.3f}*y + {:.3f}'.format(fit_r.slope, fit_r.intercept))
        plt.plot(y, x, 'go', label='inverse data')
        plt.plot(y, fct_y(y, fit_r.slope, fit_r.intercept), 'y-',
                 label='fit a={:.3f} b={:.3f}'.format(fit_r.slope, fit_r.intercept))
        plt.title('linear regression $x=a_1*y+b_1$') # yes, matplotlib speaks LaTeX
        plt.axis((8, 38, 50, 150))
        plt.ylabel('stepping period [ms]')
        plt.xlabel('speed [mm/s]')
        plt.legend(loc='upper right');
linear fit: x = -2.248*y + 144.473
```



### 1.4 Nicht-lineares Beispiel: Wurfparabel

```
In [13]: np.random.seed(98765)
         deltaT = 0.1
                                             # time steps in seconds
         period = 6
                                             # duration of flight in sec
         g = 9.81
                                             # gravity constant
         ae = 0.15
                                             # speed dependent noise amplitude
         be = 0.05
                                             # constant noise amplitude
         v0 = 15
                                             # speed at start in m/s
         numOfPoints = int(period/deltaT)
                                             # measured points
         t_a = np.zeros(numOfPoints)
                                             # time value[]
```

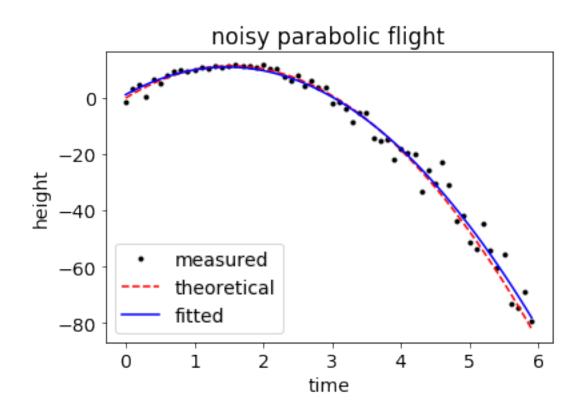
```
v_a = np.zeros(numOfPoints)
                                            # vertical speed[]
        yt_a = np.zeros(numOfPoints)
                                            # y theoretically[]
        y_a = np.zeros(numOfPoints)
                                            # y result: with noise[]
         for it in range(numOfPoints):
                                            # calculate
             t = it*deltaT
                                            # time now
            t_a[it] = t
                                            # store
             v = v0-g*t
                                            # speed reduced by gravity
            v_a[it] = v
                                            # store
                                            # squared by gravitational acceleration
             yt = -g*t**2/2+v0*t
             yt_a[it] = yt
             error = np.random.normal(loc=0, scale=ae*abs(v)+be)
             y_a[it] = yt+error
                                            # add noise
In [14]: plt.title('Ball shot up and then dropping')
        plt.ylabel('Vertical position [m]')
        plt.xlabel('Time [s]')
        plt.plot(t_a, y_a, 'k.', label='obs. vert. pos.') # observed points with noise
        plt.plot(t_a, yt_a, 'r-', label='true vert. pos.') # theoretical position
        plt.legend(loc="lower left");
```



```
fitted polynom has parameters pp=[ -4.54965459 13.37918126 1.2131438 ]
```

```
In [17]: '''compare measured and fitted values (with randomly drawn distribution)'''
    plt.plot(t_a, y_a, 'k.', label='measured')
    plt.plot(t_a, yt_a, 'r--', label='theoretical')
    py = np.polyld(pp)  # define polynomial function with fitted parameters
    plt.plot(t_a, py(t_a), 'b-', label='fitted')# show fitted locations versus time
    plt.legend(loc='lower left')
    plt.title("noisy parabolic flight")
    plt.xlabel('time')
    plt.ylabel('time')
    print('gravitational constant = {:6.3f} m/s^2'.format(-2*pp[0])) # from y ~ -g*t^2/2
    print('starting speed was v0 = {:6.3f} m/s'.format(pp[1])) # derivative at t=0

gravitational constant = 9.099 m/s^2
starting speed was v0 = 13.379 m/s
```

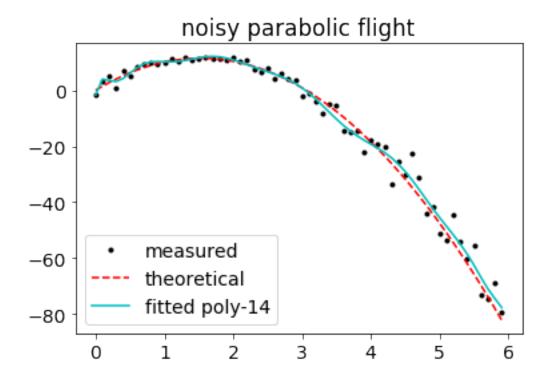


#### Siehe auch

- numpy.polyfit
- scipy.optimize.curve\_fit

```
In [18]: p14 = np.polyfit(t_a, y_a, 14) # polynomparameters from fit of degree 14 (?)
    print('fitted polynom of degree {} has parameters p14=\n{}'.format(len(p14)-1, p14))
    plt.plot(t_a, y_a, 'k.', label='measured')
```

```
plt.plot(t_a, yt_a, 'r--', label='theoretical')
        py = np.poly1d(p14)
                                             # define polynomial function with parameters
        plt.plot(t_a, py(t_a), 'c-', label='fitted poly-14')
        plt.legend(loc='lower left')
        plt.title("noisy parabolic flight");
fitted polynom of degree 14 has parameters p14=
[ -1.71045973e-03
                   7.25881832e-02 -1.37704393e+00
                                                     1.54074336e+01
  -1.12969223e+02
                   5.70392805e+02 -2.02844834e+03
                                                     5.10788156e+03
  -9.02800340e+03
                   1.09398432e+04 -8.70967673e+03
                                                     4.23721214e+03
                   1.33379787e+02 -1.67218166e+00]
  -1.11180856e+03
```



```
In [19]: '''compare polynomial coefficients and residual error'''
        pp14, residual14, rk, sv, rc = np.polyfit(t_a, y_a, 14, full=True)
        pp2, residual2, rk, sv, rc = np.polyfit(t_a, y_a, 2, full=True)
        print('polynomial models with {} / {} parameters decreases residual error from {:.1f} to {:.1f}'.
               format(len(pp2), len(pp14), residual2[0], residual14[0]))
         for ppx in [pp2, pp14]:
             1 = len(ppx)
             print('last 3 parameters of {:2d}-parameter model: {:8.2f}, {:8.2f}, {:8.2f}'.
                   format(1, ppx[1-3], ppx[1-2], ppx[1-1]))
polynomial models with 3 / 15 parameters decreases residual error from 668.9 to 581.9
last 3 parameters of 3-parameter model:
                                            -4.55,
                                                      13.38,
                                                                 1.21
last 3 parameters of 15-parameter model: -1111.81,
                                                     133.38,
                                                                -1.67
```

2 FRAGEN?

#### **Ergebnis:**

- obwohl der Restfehler weniger wird
  - für das 14-parametrige Modell
  - gegenüber dem (korrekten) parabolischen
- ist das Ergebnis zweifelhaft
  - Ein Ball steigt nicht wieder
  - der quadratische Koeffizient ist unsinnig hoch

# 2 Fragen?

# 3 Zusammenfassung beschreibende Statistik

- Datenreduktion
- KenngröSSen herausarbeiten
  - Mittelwert
  - Standardabweichung
  - Korrelationskoeffizient
- Struktur in den Daten erkennen
  - Form (Normalverteilung, Gleichverteilung, ...)
- · Anschauliche Darstellung
  - Box-Plot
  - Fehlerbalken
  - Histogramm
  - 2D-Histogramm
- Vergleichbarkeit unter ähnlichen Bedingungen
- Abhängigkeit mehrerer Variabler
  - Korrelation
  - Regression

# 4 Fragen an die Statistik

- Was ist die wahre GröSSe bei mehreren Messungen/Daten?
- Wie genau ist das erlangte Wissen?
- Was sind Ausreisser
- Effekt zwischen unterschiedlichen Versuchsbedingungen?
  - andere Wert?
  - andere Verteilung?
  - Zufall?
- Abhängigkeit wenn nichtlinear?

# 5 Ausblick

11

- Wahrscheinlichkeitstheoretische Modelle
  - Entspricht das Histogramm einer bekannten Verteilung?
  - Wie kommen die Daten zustande?
- SchlieSSende Statistik arbeitet mit Wahrscheinlichkeiten
  - Gibt es grundlegende Parameter der Daten?

## 6 Links

- Matplotlib Graphikgalerie http://matplotlib.org/gallery.html
- Pandas Graphiken: http://pandas.pydata.org/pandas-docs/stable/visualization.html

# 7 Fragen?